

Окончательное решение среднеквадратического вопроса

Достаточные статистики

Чертоги разума

Определение. Статистика $T(X_1, \dots, X_n)$ называется *достаточной*, если существует вариант условного распределения $\mu(B, t) = P(\mathbf{X} \in B | T(\mathbf{X}) = t)$, которое не зависит от параметра θ .

Теорема (критерий факторизации). Пусть $\mathbf{X} = (X_1, \dots, X_n)$ — выборка из доминируемого семейства $\mathcal{P} = \{P_\theta\}$, где P_θ имеет плотность ρ_θ по мере μ . Тогда статистика $T(\mathbf{X})$ достаточная тогда и только тогда, когда найдутся борелевские h и g такие, что

$$\rho_\theta(\mathbf{x}) = h(\mathbf{x}) \cdot g(T(\mathbf{x}), \theta).$$

Основной пример. Если модель принадлежит экспоненциальному семейству, то есть плотность в ней имеет вид

$$\rho_\theta(x) = h(x) \cdot \exp \left(g(\theta) + \sum_{i=1}^k a_i(\theta) T_i(x) \right), \quad (1)$$

то вектор $\overline{\mathbf{T}(\mathbf{X})} = (\overline{T_1(\mathbf{X})}, \dots, \overline{T_k(\mathbf{X})})$ является достаточной статистикой.

Теорема (Колмогоров, Блэкуэлл, Рао). Пусть $\tilde{\theta}(\mathbf{X})$ — несмещённая оценка $\tau(\theta)$ с конечной дисперсией, $T(\mathbf{X})$ — достаточная статистика. Тогда случайная величина $\hat{\theta}(\mathbf{X}) = E_\theta(\tilde{\theta}(\mathbf{X}) | T(\mathbf{X}))$ является несмещённой оценкой $\tau(\theta)$, причём она не хуже $\tilde{\theta}(\mathbf{X})$ в среднеквадратичном подходе:

$$\forall \theta \in \Theta: E_\theta \left(\hat{\theta}(\mathbf{X}) - \tau(\theta) \right)^2 \leq E_\theta \left(\tilde{\theta}(\mathbf{X}) - \tau(\theta) \right)^2.$$

Определение. Статистика $S(\mathbf{X})$ называется *полной*, если для любой борелевской f выполнена импликация:

$$[\forall \theta \in \Theta: E_\theta f(S(\mathbf{X})) = 0] \implies [\forall \theta \in \Theta: f(S(\mathbf{X})) = 0 \quad (P_\theta\text{-п.н.})].$$

Теорема (Леман, Шеффе). Если $T(\mathbf{X})$ — полная достаточная статистика для семейства $\{P_\theta\}$ и $E_\theta \theta^*(\mathbf{X}) = \tau(\theta)$, то $\hat{\theta}(\mathbf{X}) = E_\theta(\theta^*(\mathbf{X}) | T(\mathbf{X}))$ — лучшая оценка в среднеквадратичном подходе среди несмещённых оценок (такие оценки называют *оптимальными*).

Помимо непосредственной проверки по определению, полноту обеспечивает следующее **достаточное условие полноты**. Рассмотрим модель из экспоненциального семейства (1). Если множество $\mathbf{a}(\Theta) \subset \mathbb{R}^k$ содержит внутреннюю точку, то статистика $\overline{\mathbf{T}(\mathbf{X})}$ полна.

Главное следствие. Если для полной достаточной статистики $T(\mathbf{X})$ вы придумаете такую φ , что $E_\theta \varphi(T(\mathbf{X})) = \tau(\theta)$, то $\varphi(T(\mathbf{X}))$ будет оптимальной оценкой $\tau(\theta)$.

Aufgaben

1. Для семейства распределений

(а) $\mathcal{P} = \{\text{Bern}(p) : p \in (0, 1)\}$;

(б) $\mathcal{P} = \{\mathcal{N}(a, \sigma^2) : a \in \mathbb{R}, \sigma^2 > 0\}$;

(в) $\mathcal{P} = \{\text{Beta}(\alpha, \beta) : \alpha, \beta > 0\}$

предъявите достаточную статистику фиксированной размерности.

2. Не всякой статистикой $T(\mathbf{X})$ можно улучшать оценки посредством взятия УМО — в этом и заключается особенность достаточных статистик. Для выборки

$$X_1, \dots, X_n \sim \mathcal{N}(a, 1)$$

приведите пример Недостаточной статистики $T(\mathbf{X})$ такой, что $\mathbb{E}_a(\bar{X} | T(\mathbf{X}))$ зависит от неизвестного a и, значит, не является статистикой.

3. Докажите, что статистика $X_{(1)}$ для выборки X_1, \dots, X_n в модели сдвига

$$\mathcal{P} = \{\text{Exp}(1) + a : a \in \mathbb{R}\}$$

является полной и достаточной. Постройте с помощью неё оптимальную оценку параметра a .

4. Докажите, что в модели $U(\theta, \theta + 1)$, где $\Theta = \{\theta > 0\}$, статистика $(X_{(1)}, X_{(n)})$ является достаточной, но не полной. Есть ли в ней хоть какая-нибудь полная достаточная статистика?

5. Найдите оптимальную оценку функции $e^{-\theta}$ для выборки X_1, \dots, X_n из распределения $\text{Pois}(\theta)$.

Указание. В качестве стартовой несмещённой оценки возьмите оценку из первого листка.

6. Пусть ξ_1, \dots, ξ_{10} — н.о.р.с.в. из распределения $U[0; 11]$. Обозначим $X = \min(\xi_1, \dots, \xi_{10})$, $Y = \max(\xi_1, \dots, \xi_{10})$. С помощью арсенала достаточных статистик найдите $D(X - 4Y)$ (решения «в лоб» не принимаются).

7* (а) Достаточная статистика $S(\mathbf{X})$ называется *минимальной*, если для любой другой достаточной статистики $T(\mathbf{X})$ найдётся функция φ такая, что $S = \varphi \circ T$. Пусть про статистику $S(\mathbf{X})$ известно, что

$$\forall \mathbf{x}, \mathbf{y} : \left(S(\mathbf{x}) = S(\mathbf{y}) \iff \frac{\rho_{\theta}(\mathbf{x})}{\rho_{\theta}(\mathbf{y})} \equiv \text{const} \right),$$

где $\rho_{\theta}(\mathbf{x})$ — совместная плотность выборки. Покажите, что она является минимальной достаточной статистикой.

Замечание. Можете считать известным факт, что найдётся измеримая S^{-1} такая, что $S(S^{-1}(s)) \equiv s$.

(б) Найдите минимальную достаточную статистику в модели масштаба распределения Коши:

$$\rho_{\theta}(x) = \frac{\theta}{\pi(x^2 + \theta^2)}.$$