

# Welcome back my friends to the show that never ends

Критерий отношения правдоподобий. Проверка линейных гипотез

## Чертоги разума

Пусть  $X_1, \dots, X_n \sim P_\theta$ , где  $\theta$  берётся из  $k$ -мерной поверхности  $\Theta$ . Поставим на проверку гипотезу  $H_0: \theta \in \Theta_0$ , где  $\Theta_0 \subset \Theta$  — подповерхность размерности  $l < k$ . В качестве статистики критерия можно взять обобщение статистики из р.н.м. критерия Неймана-Пирсона:

$$LR(\mathbf{X}) = \frac{\sup_{\theta \in \Theta} \rho_\theta(\mathbf{X})}{\sup_{\theta \in \Theta_0} \rho_\theta(\mathbf{X})}.$$

Сам критерий отношения правдоподобий (КОП) имеет вид  $\{\mathbf{x}: LR(\mathbf{x}) > c\}$ . Осталось лишь подобрать  $c$  так, чтобы критерий имел нужный уровень значимости. Теорема ниже позволяет контролировать его в асимптотическом смысле:

**Теорема (Уилкс).** В некоторых условиях регулярности при верности нулевой гипотезы:

$$2 \ln LR(\mathbf{X}) \xrightarrow{d} \chi_{k-l}^2.$$

То есть критерий можно взять в виде  $\{\mathbf{x}: 2 \ln LR(\mathbf{x}) > \chi_{k-l, 1-\alpha}^2\}$ .

*Пример.*  $X_i \sim \text{Cat}(p_1, \dots, p_k)$ ,  $H_0: \mathbf{p} \in \Theta_0$ ,  $\dim \Theta_0 = l$ . Тогда

$$2 \ln LR(\mathbf{X}) = \inf_{\mathbf{p} \in \Theta_0} 2 \sum_{i=1}^k \nu_i \ln \frac{\nu_i}{np_i} \xrightarrow{d} \chi_{k-1-l}^2, \quad \nu_i = \sum_{j=1}^n I(X_j = i).$$

*Пример (линейная гипотеза).* Рассмотрим гауссовскую линейную регрессию  $\mathbf{X} = Z\boldsymbol{\theta} + \boldsymbol{\varepsilon}$ ,  $\mathbf{X} \in \mathbb{R}^n$ ,  $\boldsymbol{\theta} \in \mathbb{R}^k$ . Поставим на проверку линейную гипотезу  $H_0: T\boldsymbol{\theta} = \boldsymbol{\tau}$ , где  $T \in \mathbb{R}^{m \times k}$  ( $m < k$ ) — полного ранга. То есть проверяется принадлежность  $\boldsymbol{\theta}$  какому-то  $(k-m)$ -мерному аффинному подпространству  $\mathcal{L}_0$ . Пусть  $\hat{\boldsymbol{\theta}}$  — МНК-оценка, а  $\tilde{\boldsymbol{\theta}}$  — МНК-оценка при верности  $H_0$  (а.к.а. такой вектор, что  $Z\tilde{\boldsymbol{\theta}} = \text{proj}_{\mathcal{L}_0} \mathbf{X}$ ). Тогда

$$2 \ln LR(\mathbf{X}) = n \cdot \ln \frac{RSS_0}{RSS}, \quad \text{где } RSS = \|\mathbf{X} - Z\hat{\boldsymbol{\theta}}\|^2, \quad RSS_0 = \|\mathbf{X} - Z\tilde{\boldsymbol{\theta}}\|^2.$$

КОП можно сделать точным, если заметить, что

$$RSS \sim \chi_{n-k}^2 \perp RSS_0 - RSS = \|Z\hat{\boldsymbol{\theta}} - Z\tilde{\boldsymbol{\theta}}\|^2 \sim \chi_m^2$$

как квадраты длин проекций на ортогональные подпространства. Их отношение с точностью до константы имеет *распределение Фишера* с параметрами  $m$  и  $n-k$ :

$$F(\mathbf{X}) = \frac{(RSS_0 - RSS)/m}{RSS/(n-k)} = \frac{\chi_m^2/m}{\chi_{n-k}^2/(n-k)} \stackrel{\text{def}}{\sim} F_{m, n-k},$$

откуда КОП будет выглядеть так:  $\{\mathbf{x}: F(\mathbf{x}) > f_{m, n-k, 1-\alpha}\}$ .

## مسائل

1. Пусть  $X_i \sim \mathcal{N}(\mu, \sigma^2)$ ,  $i = 1, \dots, n$ , независимы в совокупности. Покажите, что статистика КОП для проверки  $H_0: \mu = \mu_0$  совпадает со статистикой критерия, построенного по точному ДИ для  $\mu$ .
2. Пусть  $\mathbf{X} = (X_1, \dots, X_n)$  — выборка из распределения  $U[0; \theta]$ . Чему равна статистика критерия отношения правдоподобий для проверки гипотезы  $H_0: \theta = 1$  против общей альтернативы? Каково её предельное распределение, а каково должно быть по теореме Уилкса?
3. Среди 2020 семей, имеющих двух детей, у 527 семей по 2 мальчиков, а у 476 — по 2 девочек. Можно ли на уровне значимости 0.05 считать, что полы старшего и младшего ребёнка независимы и одинаково распределены? Сформулируйте задачу на языке КОП и воспользуйтесь теоремой Уилкса для построения критерия.
4. Команда курса практикума по статистике заметила, что в первые  $2\frac{6}{7}$  недели из трёх до дедлайна в чате почти нет вопросов. По первым трём дедлайнам (получилось  $20 \times 3 = 60$  дней) они записали статистику того, сколько вопросов поступило в чат в тот или иной день (для простоты считаем эти величины независимыми):

Кол-во вопросов	0	1	2	3+
Число дней	17	19	17	7

Так как каждый студент, коих много, задаёт вопрос с какой-то вероятностью, коя мала, логично выдвинуть гипотезу, что распределение числа вопросов подчиняется Пуассону (в силу одноимённой предельной теоремы). Помогите проверить сие предположение на уровне значимости 0.05 с помощью КОП. Чему будет равно число степеней свобод к предельного распределения?

*Замечание.* Возможно, вам придётся написать пару троек строчек на Python.

5. В модели линейной регрессии  $X_i = \theta_0 + \mathbf{z}_i \boldsymbol{\theta} + \varepsilon$ , где  $\varepsilon \sim \mathcal{N}(0, \sigma^2)$ ,  $\theta_0, \boldsymbol{\theta} \in \mathbb{R}^k$ ,  $\sigma^2$  — неизвестные параметры. Постройте точный критерий для проверки адекватности модели  $H_0: \boldsymbol{\theta} = \mathbf{0}$  вида  $\{R^2 > c_\alpha\}$ , где  $R^2$  — коэффициент детерминации:

$$R^2 = 1 - \frac{\sum_{i=1}^n (X_i - \hat{\theta}_0 - \mathbf{z}_i \hat{\boldsymbol{\theta}})^2}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

6. Пусть имеется  $k$  независимых выборок  $\mathbf{X}_1, \dots, \mathbf{X}_k$ , причём  $i$ -ая из них

$$\mathbf{X}_i = (X_{i1}, \dots, X_{in_i})$$

состоит из  $n_i$  наблюдений, которые распределены как  $\mathcal{N}(\mu_i, \sigma^2)$  (дисперсии считаются равными, хоть и неизвестными). Сведя задачу к линейной регрессии, постройте точный критерий для проверки гипотезы  $H_0: \mu_1 = \mu_2 = \dots = \mu_k$  против общей альтернативы.