



Корреляционный анализ

Чертоги разума

Задача: даны две *связанные* выборки $(X_1, Y_1), \dots, (X_n, Y_n)$. Требуется проверить гипотезу об их независимости $H_0: X \perp Y$.

В непрерывном случае это тяжело, обычно проверяют их некоррелированность посредством статистик, называемых *коэффициентами корреляции*.

- Коэффициент Пирсона а.к.а выборочная корреляция выборок:

$$\hat{\rho}(\mathbf{X}, \mathbf{Y}) = \frac{\overline{\mathbf{XY}} - \bar{\mathbf{X}} \cdot \bar{\mathbf{Y}}}{\sqrt{s^2(\mathbf{X}) \cdot s^2(\mathbf{Y})}} \xrightarrow{P} \rho = \text{corr}(X_1, Y_1).$$

С помощью дельта-метода доказывается, что при верной H_0

$$\sqrt{n} \cdot \hat{\rho}(\mathbf{X}, \mathbf{Y}) \xrightarrow{d} \mathcal{N}(0, 1).$$

Для нормальных выборок распределение $\hat{\rho}$ можно уточнить (см. задачу 5).

- Коэффициент Спирмена а.к.а выборочная корреляция *рангов*, то есть таких R_i и S_i , что $X_{(R_i)} = X_i$ и $Y_{(S_i)} = Y_i$:

$$\rho_S(\mathbf{X}, \mathbf{Y}) = \frac{\overline{\mathbf{RS}} - \bar{\mathbf{R}} \cdot \bar{\mathbf{S}}}{\sqrt{s^2(\mathbf{R}) \cdot s^2(\mathbf{S})}}.$$

- Коэффициент Кенделла — нормированная разность согласованных и несогласованных пар:

$$\tau = \frac{2}{n(n-1)} \sum_{i < j} \text{sign}(X_i - X_j) \cdot \text{sign}(Y_i - Y_j).$$

Последние два коэффициента асимпт. нормальны в смысле, что

$$\frac{\rho_S}{\sqrt{D\rho_S}}, \frac{\tau}{\sqrt{D\tau}} \xrightarrow{d} \mathcal{N}(0, 1), \quad \text{где } D\rho_S = \frac{1}{n-1}, \quad D\tau = \frac{2(2n+5)}{9n(n-1)}$$

Для дискретного случая, когда $X_i \in \{1, \dots, k\}$, $Y_i \in \{1, \dots, m\}$, применяют *критерий независимости хи-квадрат*, основанный на статистике:

$$\chi^2(\mathbf{X}, \mathbf{Y}) = n \sum_{i=1}^k \sum_{j=1}^m \frac{(\nu_{ij} - \nu_{i\bullet} \nu_{\bullet j} / n)^2}{\nu_{i\bullet} \nu_{\bullet j}} \xrightarrow{d} \chi_{(k-1)(m-1)}^2, \quad n \rightarrow \infty$$

где $\nu_{ij} = \sum_{l=1}^n I(X_l = i, Y_l = j)$, $\nu_{i\bullet} = \sum_{j=1}^m \nu_{ij}$, $\nu_{\bullet j} = \sum_{i=1}^k \nu_{ij}$.

Feladatok

1. Выведите критерий независимости хи-квадрат как КОП, используя теорему Уилкса.
2. Из 360 поступающих на DS-поток юношей было принято 97, а из 82 девушек — 40. Проверить гипотезу о независимости факта поступления от пола с $\alpha = 0.01$.
3. Группа Б05-024 перед написанием контрольной по статистике решила для храбрости постоять немного в планке. Ниже приведены результаты: в первой строке записано количество минут, которое человек простоял в планке, во второй — балл за контрольную.

0.5	2.5	8.5	2	6	10	0.5	1	0.5	3	6.5	0.5	2	3.5	6.0	1.5	1
3	0	2	2	2	3	0.5	2	1	2.5	3	3	2	2	3	0	3

Посчитайте коэффициент корреляции Спирмена (можно использовать Python) и проверьте с помощью него гипотезу о том, что данные метрики независимы.

4. Докажите, что в случае, когда (X_i, Y_i) — гауссовский вектор (необязательно $X_i \perp Y_i$):
(а) имеет место сходимост

$$\sqrt{n} \cdot (\hat{\rho} - \rho) \xrightarrow{d} \mathcal{N}(0, (1 - \rho^2)^2);$$

- (б) коэффициент Кенделла несмещённо оценивает $\frac{2}{\pi} \arcsin \rho$;
- (в) коэффициент Спирмена несмещённо оценивает нечто, стремящееся к $\frac{6}{\pi} \arcsin \frac{\rho}{2}$.
5. Пусть $\hat{\rho}$ — коэффициент корреляции Пирсона, построенный по выборкам \mathbf{X} и \mathbf{Y} . Докажите, что есть эти выборки независимы и нормально распределены, то

$$\hat{\rho} \cdot \sqrt{\frac{n-2}{1-\hat{\rho}^2}} \sim T_{n-2}.$$

Указание. Найдите условное распределение $\hat{\rho}$ при фиксированной \mathbf{X} и покажите, что оно одинаково при любом условии.